LLM 推理全流程

从 Prompt 到第一个 Token

1 输入提示词

(Prompt)

今天的天气
真不错，

Prompt
（原始文本）

2 分词（Tokenization）

将文本切分为若干词元
(Token)

今天 | 的 | 天气 | 真 | 不错 | ，

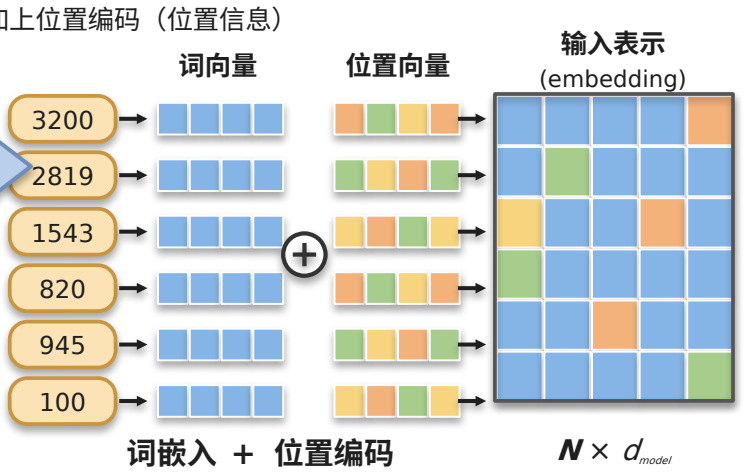
3200 | 2819 | 1543 | 820 | 945 | 100

Token IDs （数字编码）

输入序列长度 $N = 6$

3 词嵌入（Embedding）

将 Token ID 映射为高维向量，
并加上位置编码（位置信息）



4 Transformer 层堆叠

重复 L 层，每层包含多头注意力
和前馈网络（FFN/MLP 或 MoE）

第 l 层（示意）

来自上一层的
隐状态
H_{l-1}
$(N \times d_{model})$

残差连接

LayerNorm

多头注意力（Attention）

Q　K　V

因果掩码
(Causal Mask)

注意力计算
（多头并行）

注意力输出

写入 K、V
到缓存
（在 Prefill 阶段）

在 Decode 阶段
读取历史 KV
加速计算

LayerNorm

前馈网络（FFN / MLP 或 MoE）

线性变换
(W_1)

激活函数
(SiLU 等)

线性变换
(W_2)

LayerNorm

× L

5 KV Cache（键值缓存）

在推理过程中缓存每层的 K、V
（便于后续自回归生成时复用）

第 l 层的 KV Cache

K Cache
（已缓存的键）
已缓存
$(\le N \times d_k)$

V Cache
（已缓存的值）
已缓存
$(\le N \times d_v)$

Prefill 阶段：处理整个提示词

一次性计算所有输入位置的隐藏状态，并将每层的 K、V 写入缓存

最后一层输出隐藏状态
H $(N \times d_{model})$

今天
的
天气
真
不错
，

最后一个位置的向量 h_{last}
$(1 \times d_{model})$

6 取最后位置

(Last Position)

提取序列中最后一个
位置的隐藏状态

h_{last}
$(1 \times d_{model})$

7 最终归一化

(Final Norm)

RMSNorm /
LayerNorm

$\hat{h}$
$(1 \times d_{model})$

8 语言模型头

(LM Head)

线性变换到词表大小

W_{vocab}

Logits
$(1 \times |V|)$

9 解码采样（Decoding）

将 logits 转换为下一个 Token

贪心解码
(Greedy)
argmax

随机采样
(Sampling)

核采样
(Top-p)

...

10 第一个 Token（输出）

得到生成的第一个 Token 及其文本形式

2987
Token ID

晴天
解码为文本